Armazenamento distribuído e big data

Professor Jonas Bodê

Fonte: Pixabay.

Público

Roteiro

- Sistemas de armazenamento distribuído (HDFS, Ceph etc.).
- Técnicas de particionamento e sharding de dados.
- Introdução ao processamento de Big Data (MapReduce).

Público

Introdução

- Importância do armazenamento distribuído para grandes volumes de dados.
- Papel do particionamento e sharding na escalabilidade.
- Conceito inicial de processamento de Big Data.

Fonte: Pixabay.

Público

Sistemas de armazenamento distribuído

- **HDFS (Hadoop Distributed File System)**: usado em ambientes de Big Data.
- **Ceph**: armazenamento distribuído para nuvens e alta disponibilidade.
- O **HDFS** é utilizado pelo **Netflix** para processar grandes volumes de dados e treinar modelos de recomendação, enquanto o **Ceph** é adotado pela **CERN** para armazenar e gerenciar petabytes de dados de experimentos científicos.

Público

Características do armazenamento distribuído

- Distribuição de dados em múltiplos nós.
- Alta disponibilidade e tolerância a falhas.
- Balanceamento de carga para otimizar desempenho.
- Serviços, como o Google Drive, utilizam a distribuição de dados em múltiplos nós para garantir que arquivos estejam acessíveis globalmente.

Público

Técnicas de particionamento e sharding de dados

Particionamento

Divisão de dados entre servidores

Sharding

Divisão estratégica para otimizar leitura

Bancos NoSQL

Importância do banco de dados não relacional

Fonte: Pixabay.

Público

Processamento de Big Data

- MapReduce: modelo de programação para processamento distribuído.
- Execução paralela para análise eficiente de grandes volumes de dados.
- Uso em plataformas como Hadoop e Spark.

Público

Conclusão

- O armazenamento distribuído permite escalabilidade e alta disponibilidade.
- Técnicas de particionamento e sharding otimizam bancos de dados distribuídos.
- O processamento de Big Data viabiliza a análise de grandes volumes de informação.

Público

Bons estudos!

Professor Jonas Bodê

Fonte: Pixabay.

Público